



Fundamentos de Linguagem Python para Análise de Dados e Data Science

Fundamentos de Linguagem Python Para Análise de Dados e Data Science

Principais Técnicas de Análise de Séries Temporais



Existem diversas técnicas de análise de séries temporais que podem ser usadas para entender e modelar a estrutura dos dados ao longo do tempo. Algumas das principais técnicas incluem:

Decomposição de Séries Temporais: A decomposição é uma técnica que separa uma série temporal em seus componentes básicos, como tendência, sazonalidade e resíduos (ou ruído). Isso ajuda a entender melhor a dinâmica da série e facilita a modelagem e previsão.

Médias Móveis: As médias móveis são uma técnica de suavização que calcula a média de um número fixo de pontos de dados consecutivos para criar uma nova série temporal suavizada. Isso ajuda a reduzir o ruído e identificar tendências de longo prazo.

Suavização Exponencial: A suavização exponencial é outra técnica de suavização que atribui pesos exponencialmente decrescentes aos pontos de dados anteriores. Isso dá mais importância aos dados mais recentes e ajuda a identificar tendências e padrões de curto prazo.

Modelos Autorregressivos (AR): Os modelos autorregressivos são modelos lineares que usam os valores passados da própria série temporal para prever valores futuros. O número de valores passados usados no modelo é chamado de ordem do modelo AR.

Modelos de Médias Móveis (MA): Os modelos de médias móveis são modelos lineares que usam os resíduos passados (erros de previsão) para prever valores futuros. O número de resíduos passados usados no modelo é chamado de ordem do modelo MA.

Modelos ARIMA (Autoregressive Integrated Moving Average): Os modelos ARIMA combinam elementos dos modelos AR e MA e também incluem a diferenciação para tornar a série temporal estacionária. Os modelos ARIMA são amplamente utilizados para previsão de séries temporais e podem lidar com tendências e sazonalidades.

Modelos SARIMA (Seasonal ARIMA): Os modelos SARIMA estendem os modelos ARIMA para incluir termos sazonais, tornando-os adequados para séries temporais com padrões sazonais claros.

Modelos de Espaço de Estados: Os modelos de espaço de estados são uma abordagem mais geral para modelar séries temporais que podem incluir modelos lineares e não lineares, bem como modelos com efeitos fixos e aleatórios. Exemplos de modelos de espaço de estados incluem modelos de suavização exponencial de Holt-Winters e modelos de Kalman.

Métodos de Aprendizado de Máquina: Além das técnicas estatísticas tradicionais, os métodos de aprendizado de máquina, como redes neurais, máquinas de vetores de suporte e árvores de decisão, também podem ser usados para modelar e prever séries temporais. Esses métodos geralmente requerem a transformação dos dados de séries temporais em um formato adequado para modelagem de aprendizado de máquina.



Fundamentos de Linguagem Python para Análise de Dados e Data Science

Cada técnica tem suas próprias vantagens e limitações, e a escolha da técnica mais adequada depende das características da série temporal em questão, como a presença de tendências, sazonalidades e ruído, bem como os objetivos do projeto.

Análise e previsão de séries temporais é uma atividade de nível avançado no universo da Ciência de Dados e neste capítulo vamos trazer uma breve introdução ao tema. Escolhemos para este capítulo a técnica de Suavização Exponencial.